


# Batterie

dimanche 14 juillet 2024 13:35

## 1. Introduction aux batteries lithium-ion

### Composants d'une batterie lithium-ion

- Anode (généralement en graphite)
- Cathode (ex : oxyde de cobalt lithié  $\text{LiCoO}_2$  (LCO), NMC, LFP)
- Électrolyte (solvant organique avec sel de lithium)
- Séparateur




### Réactions chimiques et génération de courant

- Réaction à l'anode :  $\text{Li} \rightarrow \text{Li}^+ + e^-$
- Réaction à la cathode :  $\text{Li}^+ + \text{CoO}_2 + e^- \rightarrow \text{LiCoO}_2$
- Flux d'électrons dans le circuit externe

### Le C-rate (taux de charge ou de décharge) :

- Le C-rate (taux de charge ou de décharge) est une façon de décrire le courant auquel une batterie est chargée ou déchargée, par rapport à sa capacité nominale.
- $\text{C-rate} = I / Q_{\text{ref}}$ .

### Modèle simple




$$V = E - r \cdot I$$

### Tension de la batterie

- Tension nominale (ex : 3,7V pour une cellule Li-ion)
- Variation de la tension en fonction de l'état de charge (SOC)
- Courbe de décharge typique


### Courbe OCV



### Tableau de la série électromotrice

Demi-réaction de réduction	E° (V vs. ESH)
$\text{Li}^+ + \text{e}^- \rightarrow \text{Li}$	-3.04
$\text{K}^+ + \text{e}^- \rightarrow \text{K}$	-2.93
$\text{Ca}^{2+} + 2\text{e}^- \rightarrow \text{Ca}$	-2.87
$\text{Na}^+ + \text{e}^- \rightarrow \text{Na}$	-2.71
$\text{Mg}^{2+} + 2\text{e}^- \rightarrow \text{Mg}$	-2.37
$\text{Al}^{3+} + 3\text{e}^- \rightarrow \text{Al}$	-1.66
$\text{H}_2\text{O} + 2\text{e}^- \rightarrow \text{H}_2 + 2\text{OH}^-$	-0.83
$\text{Zn}^{2+} + 2\text{e}^- \rightarrow \text{Zn}$	-0.76
$\text{Fe}^{2+} + 2\text{e}^- \rightarrow \text{Fe}$	-0.44
$\text{Pb}^{2+} + 2\text{e}^- \rightarrow \text{Pb}$	-0.13
$2\text{H}^+ + 2\text{e}^- \rightarrow \text{H}_2$	0.00
$\text{Cu}^{2+} + 2\text{e}^- \rightarrow \text{Cu}$	0.34
$\text{O}_2 + 2\text{H}_2\text{O} + 4\text{e}^- \rightarrow 4\text{OH}^-$	0.40
$\text{Fe}^{3+} + \text{e}^- \rightarrow \text{Fe}^{2+}$	0.77
$\text{Ag}^+ + \text{e}^- \rightarrow \text{Ag}$	0.80
$\text{Hg}_2^{2+} + 2\text{e}^- \rightarrow 2\text{Hg}$	0.92
$\text{O}_2 + 4\text{H}^+ + 4\text{e}^- \rightarrow 2\text{H}_2\text{O}$	1.23
$\text{Cl}_2 + 2\text{e}^- \rightarrow 2\text{Cl}^-$	1.36
$\text{Au}^{3+} + 3\text{e}^- \rightarrow \text{Au}$	1.50

### Essai de caractérisation OCV




### Capacité de la batterie

- Définition (en Ah ou mAh)
- Méthodes de mesure (décharge complète à courant constant)

$$C = I \times t$$


$$C = \int_0^t I(t) dt$$



### Résistance interne

- Elle est généralement exprimée en ohms ( $\Omega$ ) ou en milliohms (m $\Omega$ ).
- Méthodes de mesure : On applique une brève impulsion de courant et on mesure la chute de tension instantanée.

Profil HPPC :



### État de charge (SOC - State of Charge)

- La quantité d'énergie électrique restante dans une batterie par rapport à sa capacité totale.

$$SOC = \left( \frac{\text{Capacité restante}}{\text{Capacité totale}} \right) \times 100\%$$

- Méthodes de mesure (coulomb counting, tension en circuit ouvert)

$$SOC(t) = SOC(0) + \frac{1}{Q} \int_0^t I(t) dt$$

Exemple un algorithmes d'estimation d'état du charge : (comme le filtre de Kalman)

### État de santé (SOH - State of Health)

- State Of Health. Etat de santé de la batterie qui indique son taux de vieillissement, défini à partir de la capacité électrique Q et/ou de la résistance électrique R par rapport à leur valeur à l'instant initial t<sub>0</sub>
- Méthodes d'estimation (capacité résiduelle, augmentation de la résistance interne)

$$SOH = \frac{Q(t)}{Q(t_0)} \text{ ou } SOH = \frac{R(t)}{R(t_0)}$$

### Vieillessement de la batterie

Les modes de vieillissement :

- Calendaire.
- Cyclage en charge et décharges CC et WLTP.
- Haut taux de charge et décharge
- température

Check-up ( Relever la capacité électrique et la résistance électrique de la cellule )

Check-up CAPA : une décharge nominale (décharge complète à C/2) représente la capacité électrique de la batterie dans son état actuel.

Check-up DCIR : Basée sur le profil HPPC

pulse de courant CC de 30 s

pause de 5 min


régénération (remise à SOC) CC à ± C/3

pause de 1 h

Essai de caractérisation du vieillissement : RPT0 => cycling\_1=> RPT1 => ..... la condition de fin de vie de la cellule (75% de la capacité initiale)

SOH\_PHEV\_CDPO\_VRS

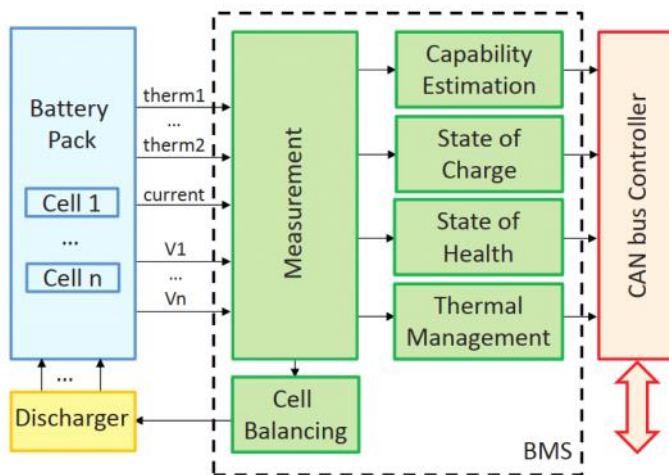
## SOH



Relation avec d'autres points de référence :

- BOL (Beginning of Life) : début de vie, capacité à 100%
- MOL8 (Middle of Life 80%) : milieu de vie, capacité à 80%
- EOL (End of Life) : fin de vie, souvent définie lorsque la capacité atteint 70-80% de la capacité initiale

## 2. Introduction aux systèmes de gestion de batterie (BMS)



### Composants principaux d'un BMS

- Microcontrôleur
- Capteurs de tension et de courant
- Capteurs de température
- Circuit de protection
- Système de communication

### Fonctions principales du BMS


- Surveillance de l'état de la batterie
- Protection contre les conditions anormales
- Équilibrage des cellules
- Gestion thermique
- Communication avec les systèmes externe

### Mesure et estimation des paramètres clés


- Tension des cellules et du pack
- Courant de charge/décharge
- Température
- État de charge (SOC)
- État de santé (SOH)

### Algorithmes d'estimation du SOC

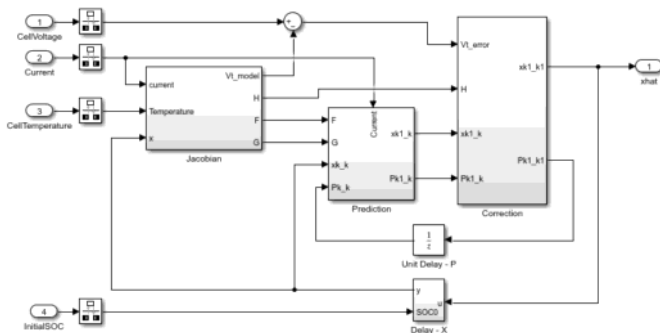
- Méthode du comptage de Coulomb



- Méthode basée sur la tension en circuit ouvert



- Filtre de Kalman



### Algorithmes d'estimation du SOH

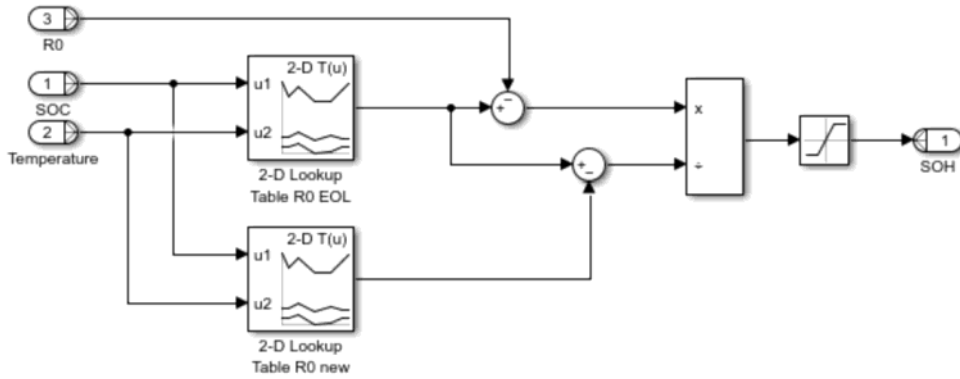
$$\text{SOH\_capacité} = (\text{Capacité\_actuelle} / \text{Capacité\_nominale}) * 100\%$$

$$\text{Capacité\_actuelle} = \text{Capacité\_précédente} + \int (I_{\text{charge}} - I_{\text{décharge}}) dt$$

$$\text{SOH\_résistance} = (R_{\text{référence}} / R_{\text{actuelle}}) * 100\%$$

$$R = \Delta V / \Delta I$$

$$\text{SOH} = \frac{R_{\text{EOL}} - R_0}{R_{\text{EOL}} - R_{0,\text{new}}}$$



En pratique, de nombreux BMS utilisent une combinaison de ces méthodes pour une estimation plus robuste du SOH :

$$\text{SOH} = w_1 * \text{SOH\_capacité} + w_2 * \text{SOH\_résistance}$$

### Équilibrage des cellules

- Importance de l'équilibrage
- Méthodes passives
- Méthodes actives



- État initial : BalancingOFF
  - L'équilibrage est désactivé
  - La commande d'équilibrage (BalCmd) est mise à false
  - La différence de tension entre les cellules (DeltaCellVolt) est calculée
- Transition vers BalancingON :
  - Se produit quand l'équilibrage est activé (flgEnBalancing)
  - L'état du BMS n'est pas en mode conduite (BMS\_State != BMS\_Driving)
  - Un certain temps s'est écoulé (after(BalOffWait,sec))
  - La différence de tension entre cellules dépasse la valeur cible (DeltaCellVolt > TargetDeltaV)
- État BalancingON :
  - L'équilibrage est activé
  - La différence de tension entre cellules est recalculée
- Sous-états de BalancingON : a. BalActive :
  - La commande d'équilibrage est activée pour les cellules dont la tension dépasse le seuil cible
  - Le drapeau flgBalCompl est mis à jour
- b. BalNotActive :
  - État par défaut quand l'équilibrage n'est pas actif
- Transitions entre les sous-états :
  - De BalNotActive à BalActive : après un délai et si la différence de tension dépasse toujours le seuil
  - De BalActive à BalNotActive : quand flgBalCompl est vrai (équilibrage terminé)
- Retour à BalancingOFF :

- Se produit quand le BMS passe en mode conduite
- Ou après un certain délai d'attente (BalOnWait)

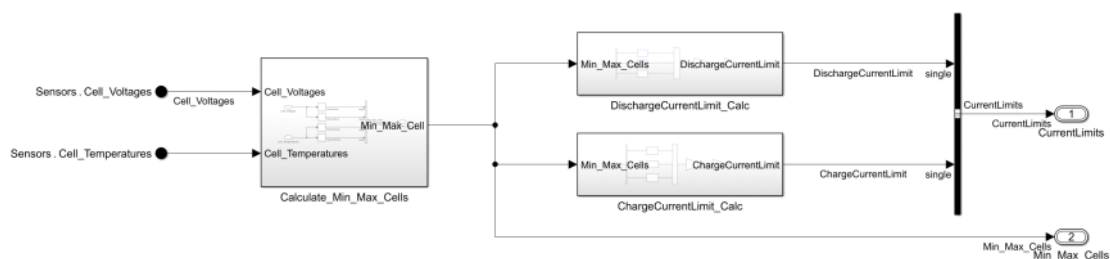
Méthodes passives :

- Dissipation de l'énergie excédentaire des cellules les plus chargées
- Simple mais moins efficace énergétiquement
- Généralement utilisé pendant la charge


Méthodes actives :

- Transfert d'énergie entre les cellules
- Plus efficace mais plus complexe à mettre en œuvre
- Peut être utilisé pendant la charge et la décharge

### Limitation de courant



- Collecte des données:
  - Le système collecte les tensions (Cell\_Voltages) et les températures (Cell\_Temperatures) de chaque cellule de la batterie.
- Calcul des valeurs minimales et maximales:
  - Le bloc "Calculate\_Min\_Max\_Cells" détermine les valeurs minimales et maximales des tensions et températures des cellules.



Calcul des limites de courant:

- Deux limites sont calculées : une pour la décharge (DischargeCurrentLimit) et une pour la charge (ChargeCurrentLimit).
- L'image 2 montre le détail du calcul pour la limite de courant de décharge.

Détermination de la limite de courant de décharge:

- Trois facteurs sont pris en compte : a) MinCellVoltDchrgCurrentLim : basé sur la tension minimale des cellules b) LowTempDchrgCurrentLim : basé sur la température minimale des cellules c) HighTempDchrgCurrentLim : basé sur la température maximale des cellules
- Ces trois valeurs passent par une fonction "min" pour sélectionner la plus restrictive.

### Gestion thermique

- Importance du contrôle de la température
- Méthodes de refroidissement
- Stratégies de gestion thermique

### Communication et interface

- Protocoles de communication (CAN, LIN, etc.)
- Interface avec le système hôte
- Journalisation des données et diagnostics

### Sécurité et protection



- Protection contre la surcharge/décharge
- Protection contre les courts-circuits
- Protection thermique
- Isolation galvanique

### 3. Banc d'essai cellule

#### Enceinte thermostatique

Exemple : Le centre d'essai électrique du CRITT M2A


chaque enceinte contient quatre voies d'essais



Instrumentation : Deux borne de puissance / une sortie sense / quatre sorties thermocouple / deux sorties 4-20 mA  
Une console affiche en temps réel les mesures en courant, tension et température de chaque voie. (Fiche CAN et une fiche Ethernet)



#### Montage de la cellule



#### Estimateur global de SOH

Estimer le State of Health (SOH) de n'importe quelle batterie en utilisant les données initiales de la batterie et le nombre de cycles de charge/décharge.

#### Données d'entrée :

- nominal\_voltage : Tension nominale de la batterie.
- nominal\_capacity : Capacité nominale de la batterie.
- C-rate : Taux de charge/décharge.
- ambient\_temperature : Température ambiante.
- charge\_discharge\_cycles : Nombre de cycles de charge/décharge.

#### Données de sortie :

- SOH : State of Health de la batterie.

#### Données d'apprentissage :

	A	B	C	D	E	F	G	H
1	Projet	nominal_voltage	nominal_capacity	C-rate	ambient_temperature	charge_discharge_cycles	SOH	Capa
2	PHEV CDPO VRS	3.65	60	60	35	0	100	61,78165
3		3.65	60	60	35	1	97,80475	60,42539
4		3.65	60	60	35	2	97,45878	60,21164
5		3.65	60	60	35	3	97,05348	59,96124
6		3.65	60	60	35	4	96,12993	59,39066
7		3.65	60	60	35	5	95,20134	58,81696
8		3.65	60	60	35	6	97,38698	58,39444
9		3.65	60	60	35	7	93,69961	57,88917
10		3.65	60	60	35	8	92,96088	57,43276
11		3.65	60	60	35	9	92,36968	57,06751
12		3.65	60	60	35	10	91,94534	56,80535
13	PHEV CDPO 6XANT	3.65	60	60	25	0	100	60,25264
14		3.65	60	60	25	1	98,43711	59,31095
15		3.65	60	60	25	2	98,13136	59,12673
16		3.65	60	60	25	3	97,37713	58,67229
17		3.65	60	60	25	4	96,77524	58,30964
18	eP74 - 6XBCD	3.65	242	121	35	0	100	241,8367
19		3.65	242	121	35	1	97,69128	236,2534
20		3.65	242	121	35	2	96,49369	233,3572
21		3.65	242	121	35	3	95,80531	231,6924
22	eD85 - 7XAEQ	3.65	139	69,5	35	0	100	289,5282
23		3.65	139	69,5	35	1	98,83876	286,1661
24		3.65	139	69,5	35	2	97,18948	281,391
25		3.65	139	69,5	35	3	97,18948	281,391
26								

#### Algorithme d'apprentissage et test :

```
import pandas as pd
import numpy as np
from sklearn.model_selection import train_test_split, cross_val_score
from sklearn.preprocessing import StandardScaler
from sklearn.ensemble import RandomForestRegressor
from sklearn.metrics import mean_squared_error, r2_score
from sklearn.pipeline import make_pipeline
from sklearn.linear_model import LinearRegression
from sklearn.neural_network import MLPRegressor
# Charger les données depuis le fichier Excel
data = pd.read_excel(r"C:\Users\Atrani\Desktop\Projet\Batterie\battery_data.xlsx")
# Sélectionner les colonnes pertinentes pour l'analyse
columns_to_use = ['nominal_voltage', 'nominal_capacity', 'C-rate', 'ambient_temperature', 'charge_discharge_cycles', 'SOH']
data = data[columns_to_use]
# Séparer les caractéristiques (X) et la cible (y)
X = data.drop('SOH', axis=1)
y = data['SOH']
# Ajouter des caractéristiques non linéaires
X['cycles_squared'] = X['charge_discharge_cycles'] ** 2
X['capacity_rate_ratio'] = X['nominal_capacity'] / X['C-rate']
```

```

# Diviser les données en ensembles d'entraînement et de test
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)
# Créer un pipeline avec standardisation et modèle pour RF, LR et NN
rf_model = make_pipeline(StandardScaler(), RandomForestRegressor(n_estimators=100, random_state=42))
lr_model = make_pipeline(StandardScaler(), LinearRegression())
nn_model = make_pipeline(StandardScaler(), MLPRegressor(hidden_layer_sizes=(64, 32), max_iter=1000, random_state=42))
# Entraîner les modèles
rf_model.fit(X_train, y_train)
lr_model.fit(X_train, y_train)
nn_model.fit(X_train, y_train)
# Fonction pour évaluer les modèles
def evaluate_model(name, model, X, y, X_test, y_test):
    pred = model.predict(X_test)
    print(f"\n{name}:")
    print(f"MSE: {mean_squared_error(y_test, pred)}")
    print(f"R²: {r2_score(y_test, pred)}")
    print(f"Cross-validation score: {np.mean(cross_val_score(model, X, y, cv=5))}")
# Évaluer les modèles
evaluate_model("Random Forest", rf_model, X, y, X_test, y_test)
evaluate_model("Linear Regression", lr_model, X, y, X_test, y_test)
evaluate_model("Neural Network", nn_model, X, y, X_test, y_test)
# Exemple de prédiction
exemple = pd.DataFrame({
    'nominal_voltage': [3.65],
    'nominal_capacity': [139],
    'C-rate': [69.5],
    'ambient_temperature': [35],
    'charge_discharge_cycles': [0]
})
exemple['cycles_squared'] = exemple['charge_discharge_cycles'] ** 2
exemple['capacity_rate_ratio'] = exemple['nominal_capacity'] / exemple['C-rate']
print(f"\nPrédiction RF pour l'exemple: {rf_model.predict(exemple)[0]}")
print(f"Prédiction LR pour l'exemple: {lr_model.predict(exemple)[0]}")
print(f"Prédiction NN pour l'exemple: {nn_model.predict(exemple)[0]}")
# Afficher l'importance des caractéristiques pour le Random Forest
#feature_importance = rf_model.named_steps['randomforestregressor'].feature_importances_
#feature_names = X.columns
#for name, importance in zip(feature_names, feature_importance):
#    print(f"Importance de {name}: {importance}")C

```

## Analyse des données d'apprentissage

### Données disponibles :

- Les données contiennent les informations suivantes pour différentes batteries :
  - nominal\_voltage : 3.65 V pour toutes les batteries.
  - nominal\_capacity : Varie entre 60, 242, et 139.
  - C-rate : Varie entre 60, 121, et 69.5.
  - ambient\_temperature : Varie entre 25 et 35°C.
  - charge\_discharge\_cycles : Varie entre 0 et 10.
  - SOH : Données de l'état de santé de la batterie.
  - Capa : Capacité mesurée.

### Modèles de prédiction

- Trois modèles ont été utilisés pour la prédiction :
  - Random Forest (RF)
  - Linear Regression (LR)
  - Neural Network (NN)

### Exemple de prédiction

Pour l'exemple donné avec les caractéristiques suivantes :

- nominal\_voltage: 3.65
- nominal\_capacity: 139
- C-rate: 69.5

- ambient\_temperature: 35
- charge\_discharge\_cycles: 0

#### Résultats des prédictions

Les résultats obtenus pour l'exemple sont :

- Random Forest (RF) : 99.35
- Linear Regression (LR) : 99.22
- Neural Network (NN) : 103.81

#### Nouvel exemple avec les caractéristiques suivantes :

- nominal\_voltage: 3.65
- nominal\_capacity: 139
- C-rate: 69.5
- ambient\_temperature: 35
- charge\_discharge\_cycles: 3

#### Résultats des prédictions

Les résultats obtenus pour ce nouvel exemple sont :

- Random Forest (RF) : 96.95
- Linear Regression (LR) : 97.37
- Neural Network (NN) : 90.43

#### Analyse des résultats

1. Random Forest :

- La prédiction de RF (99.35) est très proche de la réalité (SOH initial de 100).
- Indique que le modèle Random Forest est capable de capturer efficacement les relations non linéaires dans les données.

2. Linear Regression :

- La prédiction de LR (99.22) est également proche de la réalité, mais légèrement inférieure à celle de RF.
- Indique que la régression linéaire fonctionne bien pour ces données, mais peut ne pas capturer toutes les complexités.

3. Neural Network :

- La prédiction du NN (103.81) est légèrement au-dessus de la réalité.
- Peut indiquer un léger surajustement ou une tendance à la surévaluation pour des données non vues.

#### Conclusion

- Random Forest : semble être le modèle le plus performant et précis pour estimer le SOH des batteries avec les données fournies. Il capture efficacement les relations complexes et non linéaires présentes dans les données.
- Linear Regression fournit des résultats satisfaisants et peut être utile pour des estimations rapides et simples.
- Neural Network peut avoir besoin d'ajustements supplémentaires ou d'un plus grand ensemble de données pour éviter la surévaluation et améliorer la précision.

En résumé, pour l'application spécifique d'estimation du SOH des batteries, le modèle Random Forest est recommandé pour des prédictions précises et fiables.